Détection de fraude par carte bancaire

Analyse statistique & régression logistique

Francky Roosevelt PETNGA TCHAKOUNTEU Junwen XIAO Antoine CHANEL
Achour AIT ARAB

Sorbonne Université — Master 2 Ingénierie Mathématique

Promotion 2025/2026

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Contexte (classe rare) & objectifs

Données

- **10 000** transactions
- Cible : `is_fraud` (`Legit` vs `Fraud`)
- Fraude : **151** cas (**1.51%**)

Objectifs

- **Ranking** : prioriser les transactions à risque (PR AUC)
- **Probabilités** : scores exploitables (Brier, calibration, ECE)
- **Interprétation** : facteurs métiers (OR, IC 95%)

Déséquilibre des classes

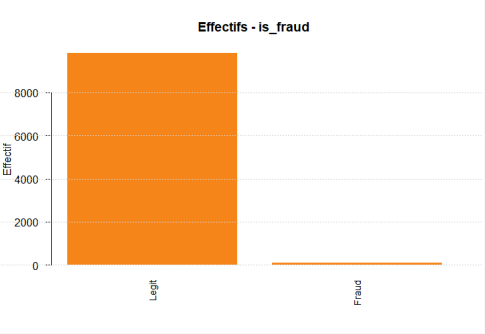

En fraude rare, ROC peut paraître excellent même si la précision est moyenne : on privilégie PR AUC.

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Variables (résumé)

Dictionnaire (compact)

Variable	Description
`amount`	Montant transaction
`transaction_hour`	Heure (0–23)
`merchant_category`	Catégorie marchand (5 modalités)
`foreign_transaction`	Internationale (No/Yes)
`location_mismatch`	Incohérence géographique (No/Yes)
`device_trust_score`	Confiance appareil (25–99)
`velocity_last_24h`	Nombre transactions sur 24h
`cardholder_age`	Âge (18–69)
`is_fraud`	Cible (Legit/Fraud)

Protocole d'évaluation

Split **stratifié** 80/20 (seed=123). Test : **2001** obs dont **31** fraudes ($\approx$ 1.55%).

Prétraitement (choix robustes)

Contrôles qualité

- NA : **0** ; doublons `transaction_id` : **0**
- Variables binaires/catégorielles $\rightarrow$ `factor`

Feature engineering

- `transaction_hour` $\rightarrow$ `hour_group` (6 tranches)
- Montant : $\texttt{log_amount} = \log(1 + \texttt{amount})$, puis suppression `amount`

Pondération (option)

- **unweighted** : probabilités "naturelles"
- **weighted** : poids fraude ≈ 66
- souvent : meilleure sensibilité mais calibration dégradée

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Univarié — distributions (variables clés)

Montant (amount)

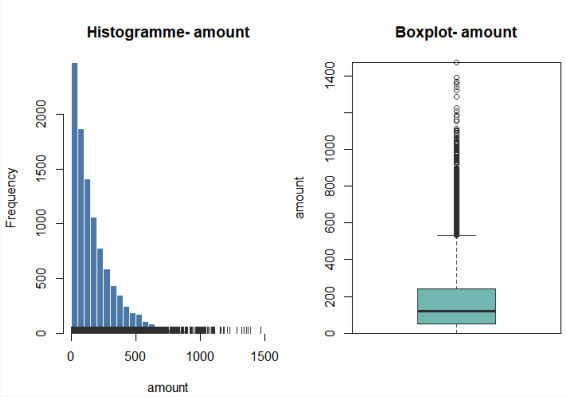

Asymétrie à droite ⇒ transformation log.

Confiance appareil (device_trust_score)

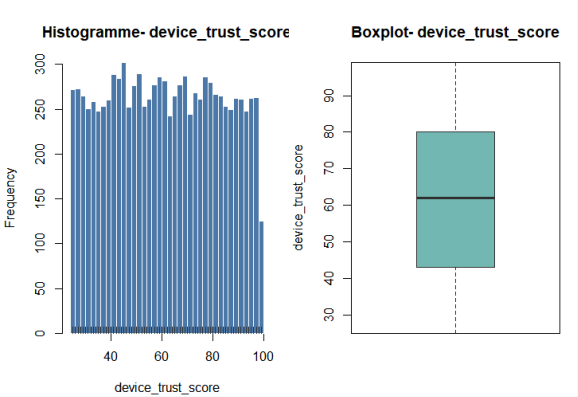

Variable bornée, potentiellement très discriminante.

Univarié — distributions (activité & contexte)

Vélocité (`velocity_last_24h`)

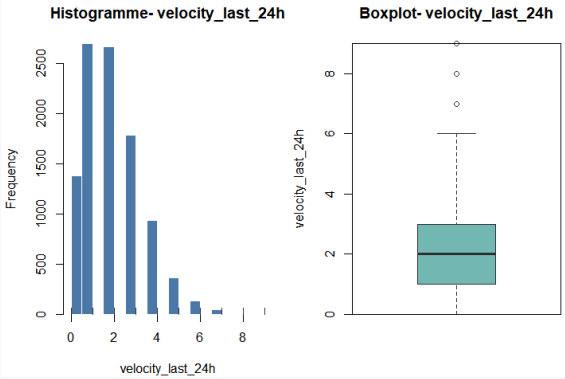

Comptage, quelques extrêmes.

Âge (`cardholder_age`)

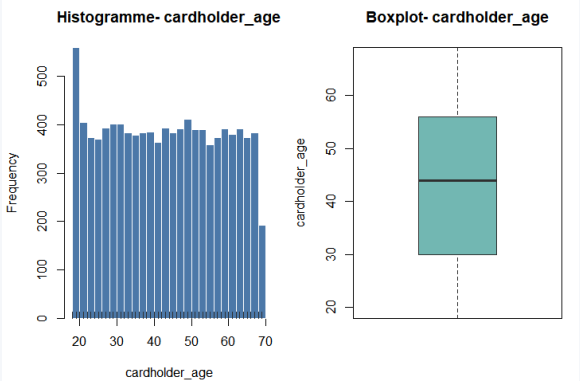

Distribution équilibrée, peu d'anomalies.

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Bivarié — tests numériques (résumé)

Synthèse (Welch + Wilcoxon)

Variable	Welch (p-value)	Wilcoxon (p-value)	BF (p-value)
`amount`	0.0456	0.572	0.00860
`device_trust_score`	1.15×10^{-40}	2.54×10^{-43}	1.43×10^{-12}
`velocity_last_24h`	2.66×10^{-12}	8.81×10^{-15}	9.05×10^{-12}
`cardholder_age`	0.952	0.956	0.277

Lecture

Très robustes : `device_trust_score` (Fraud $\downarrow$), `velocity_last_24h` (Fraud $\uparrow$).
Montant : signal en queue (Welch significatif, Wilcoxon non). **Âge :** pas de signal bivarié.

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Catégorielles — tests & tailles d'effet (résumé)

χ^2, Cramér V, OR (si 2x2)

Variable	p-value (χ^2)	Cramér V	OR (IC 95%)
`hour_group`	4.80×10^{-95}	0.212	–
`merchant_category`	0.1918	0.025	–
`foreign_transaction`	6.80×10^{-77}	0.186	11.869 [8.446 ; 16.723]
`location_mismatch`	4.63×10^{-67}	0.173	10.518 [7.47 ; 14.785]

Lecture métier

Très forts : international, mismatch, sur-fraude nocturne (00–03).
Faible / non robuste : `merchant_category` en bivarié (peut aider via interactions).

Catégorielles — `foreign_transaction` (signal majeur)

Contingence + taux

Modalité	Legit	Fraud	Taux fraude
No	8953	69	0.76%
Yes	896	82	8.38%

Interprétation

Transaction internationale : **taux multiplié** $\approx$ 11x, OR $\approx$ 11.87.
Cohérent avec usage inhabituel / attaques transfrontalières.

Graphique

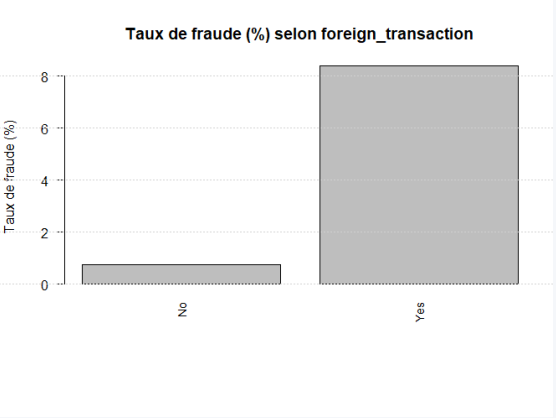

Catégorielles — `location_mismatch` (signal explicite)

Contingence + taux

Modalité	Legit	Fraud	Taux fraude
No	9064	79	0.86%
Yes	785	72	8.40%

Interprétation

Mismatch : **signal de risque "métier"** (compromission, usage à distance).
OR $\approx$ 10.52, effet très proche de l'international.

Graphique

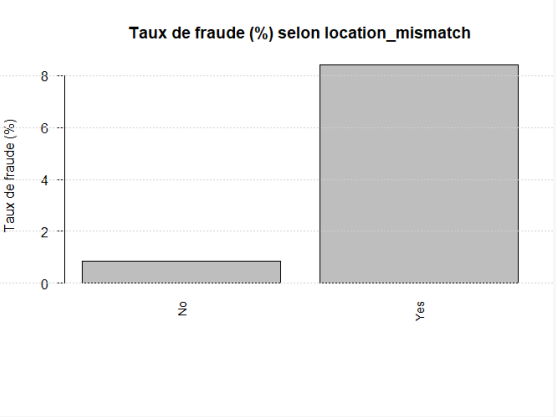

Catégorielles — hour_group (effet nocturne)

Taux par tranche

Tranche	Legit	Fraud	Taux fraude
00–03	1531	121	7.32%
04–07	1636	5	0.30%
08–11	1586	7	0.44%
12–15	1722	5	0.29%
16–19	1703	7	0.41%
20–23	1671	6	0.36%

Graphique

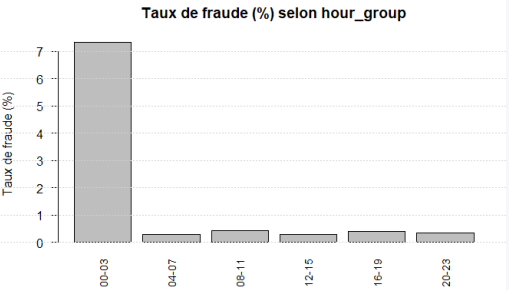

Interprétation

Sur-fraude **concentrée** sur 00–03 : attaques automatisées / contrôles plus faibles / usages atypiques.

Catégorielles — `merchant_category` (pas robuste en bivarié)

Taux par catégorie

Catégorie	Legit	Fraud	Taux
Clothing	2026	24	1.17%
Electronics	1899	24	1.25%
Food	2058	35	1.67%
Grocery	1905	39	2.01%
Travel	1961	29	1.46%

Graphique

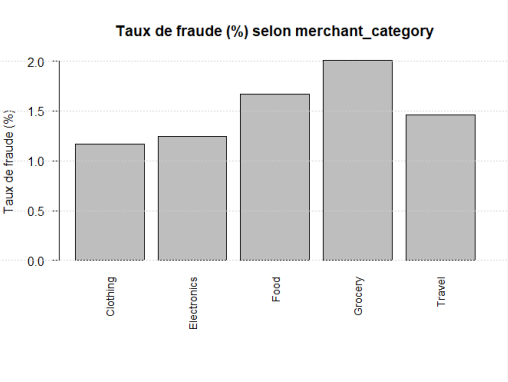

Interprétation

$p = 0.1918$, Cramér $V = 0.025$: effet faible en bivarié. **Peut devenir utile via interactions** (catégorie $\times$ international, catégorie $\times$ nuit).

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Pourquoi la régression logistique ? (scoring & interprétabilité)

Objectif

Construire un score probabiliste :

$$\hat{p}(\mathrm{x}) = P(\texttt{Fraud} \mid \mathrm{x})$$

Fraude rare

- la métrique clé devient **PR AUC**
- la décision dépend du **coût** FP/FN

Atouts

- **Probabilités** directement exploitables
- **Interprétation** par odds ratios : $\mathrm{OR} = \exp(\beta)$
- **Base solide** pour du tri d'alertes (ranking)

Modèle logistique : formule & lecture

Formule

$$\pi(\mathrm{x}) = \sigma(\eta(\mathrm{x})) = \frac{1}{1+\exp(-\eta(\mathrm{x}))}, \qquad \eta(\mathrm{x}) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j$$

$$\log\left(\frac{\pi(\mathrm{x})}{1-\pi(\mathrm{x})}\right) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j$$

Odds ratio (interprétation)

À covariables fixes, +1 unité sur x_j multiplie les odds par :

$$\mathrm{OR}_j = \exp(\beta_j)$$

Interactions

Si x_j interagit avec une variable catégorielle, l'effet de x_j dépend de la modalité : l'OR "global" n'existe pas, on interprète par contexte (modalité de référence + terme d'interaction).

Les 6 modèles comparés (structure)

Familles

Modèle	Structure
`MAIN_unw` / `MAIN_w`	Effets principaux : `log_amount`, `device_trust_score`, `velocity_last_24h`, `cardholder_age` + catégorielles (`merchant_category`, `foreign_transaction`, `location_mismatch`, `hour_group`).
`INTER_unw` / `INTER_w`	+ **non-linéarités** (termes quadratiques) + **interactions ciblées** (métier).
`STEP_unw` / `STEP_w`	Sélection **stepwise AIC** depuis `MAIN` avec interactions à deux facteurs.

Idée clé

MAIN = baseline interprétable ; **INTER** = capture d'effets réels (non-linéaires/interactions) ; **STEP** = compromis automatique mais plus instable / plus difficile à expliquer.

Pondération de classes : ce que ça change

Principe

Modèle pondéré : maximisation d'une log-vraisemblance **pondérée**. Les fraudes reçoivent un poids ≈ 66 (ratio Legit/Fraud du train).

Effet attendu (observé ici)

- Recall peut augmenter, mais **probabilités moins calibrées** (intercepts très négatifs, seuils extrêmes).
- Les seuils optimisant F1 deviennent très élevés ($\sim 0.98 - 0.99$) car les scores ne représentent plus une proba "naturelle".

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Métriques utilisées (pourquoi elles sont adaptées)

Métriques de ranking (fraude rare)

- **PR AUC** : performance côté fraude (prioritaire)
- **ROC AUC** : discrimination globale (peut être trompeuse en classe rare)

Métriques probabilistes (scoring)

- **Brier** : qualité globale des probabilités
- **Calibration** intercept/slope : idéal (0,1)
- **ECE** : écart moyen "confiance vs réalité" (10 bins)

Métriques décisionnelles

Seuil choisi par **max F1** sur le test (grille) + matrice de confusion. En pratique : seuil dépend du coût FP/FN et de la capacité d'investigation.

Comparaison des modèles (test) — ranking & calibration

AUC / calibration / score

Modèle	ROC	PR	Brier	Int.	Slope	ECE	Seuil
INTER_unw	0.9637	**0.8243**	**0.0052**	-0.657	0.437	**0.004**	0.45
INTER_w	0.9612	0.8102	0.0132	-2.018	0.273	0.015	0.99
MAIN_unw	**0.9947**	0.8038	0.0063	-0.313	**0.761**	**0.004**	0.45
STEP_unw	0.9339	0.8007	0.0067	-1.497	0.127	0.006	0.93
STEP_w	0.9330	0.7679	0.0080	-1.819	0.117	0.008	0.99
MAIN_w	0.9885	0.7320	0.0289	-3.142	0.549	0.038	0.98

Lecture

Meilleur scoring/ranking : `INTER_unw` (PR AUC max, Brier min, ECE faible). **Meilleure calibration :** `MAIN_unw` (slope 0.761, plus proche de 1).

Décision au seuil optimal (max F1) — comparaison

Matrice de confusion (test)

Modèle	TP	FP	FN	Precision	Recall	F1
MAIN_unw	23	6	8	0.7931	0.7419	0.7667
MAIN_w	22	13	9	0.6286	0.7097	0.6667
INTER_unw	23	5	8	**0.8214**	0.7419	0.7797
INTER_w	23	7	8	0.7667	0.7419	0.7541
STEP_unw	**24**	6	**7**	0.8000	**0.7742**	**0.7869**
STEP_w	**24**	8	**7**	0.7500	**0.7742**	0.7619

Lecture

Décision (F1) : STEP_unw est légèrement meilleur. **Scoring :** INTER_unw reste préféré pour proba.

Courbes ROC/PR + calibration (best model)

ROC / PR (6 modèles)

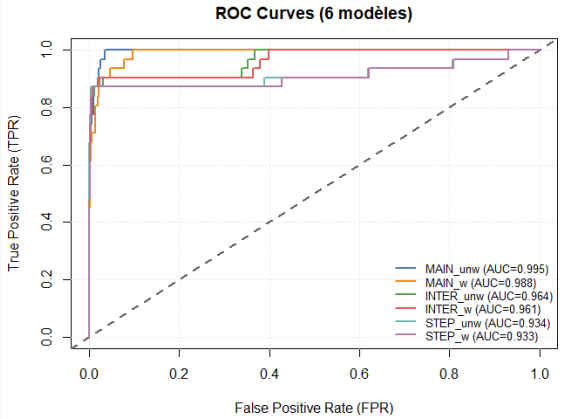

INTER_unw : distribution + calibration

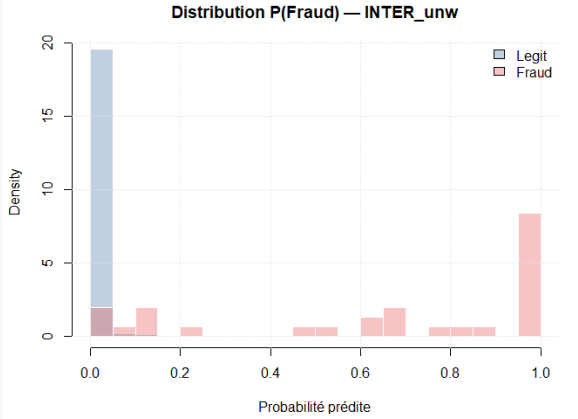

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Top coefficients (INTER_unw) — OR & significativité

Top termes (sortie R, OR et IC 95%)

Terme	Coef	OR	IC 95% OR	p-value
location_mismatchYes	8.1432	3439.980	[541.426 ; 21856.090]	6.03×10^{-18}
device_trust_score	-0.2512	0.778	[0.723 ; 0.837]	2.46×10^{-11}
foreign_transactionYes	8.3008	4027.262	[317.542 ; 51076.235]	1.51×10^{-10}
I(log_amount$\hat{2}$)	0.4027	1.496	[1.267 ; 1.766]	2.03×10^{-6}
log_amount	-3.0653	0.047	[0.012 ; 0.182]	9.86×10^{-6}
I(velocity_last_24h$\hat{2}$)	0.2008	1.222	[1.102 ; 1.356]	1.55×10^{-4}
merchant_categoryElectronics	2.6244	13.796	[2.336 ; 81.492]	3.78×10^{-3}
merchant_categoryGrocery	1.6250	5.079	[1.034 ; 24.954]	4.54×10^{-2}
hour_group04-07	-10.6516	0.000	[0.000 ; 0.979]	4.95×10^{-2}

Avertissement (important)

Des OR énormes (plusieurs milliers) peuvent signaler une quasi-séparation (combinaisons très discriminantes). En pratique : envisager régularisation / Firth + recalibration.

Interprétation métier (INTER_unw)

Ce que le modèle apprend (cohérent avec le bivarié)

- **Risque massif** : `foreign_transactionYes` et `location_mismatchYes` $\Rightarrow$ marqueurs métiers majeurs.
- **Protecteur** : `device_trust_score` (OR ≈ 0.778 par point) $\Rightarrow$ device fiable = risque $\downarrow$.
- **Comportement** : `velocity_last_24h` non-linéaire (terme $\cdot^2$) $\Rightarrow$ risque accélère quand l'activité augmente.
- **Montant** : relation non linéaire via `log_amount` + `log_amount²` (signal surtout en queue).
- **Temps** : tranches "hors nuit" souvent moins risquées que la référence 00–03.

Implication opérationnelle

Les règles "métier" (international/mismatch/nuit) + signaux comportementaux (device, vélocité) expliquent l'essentiel du risque.

Plan

1. Contexte & objectifs
2. Données & préparation
3. Analyse univariée
4. Analyse bivariée (numériques)
5. Analyse bivariée (catégorielles)
6. Régression logistique
7. Évaluation & résultats
8. Interprétation (coefficients)
9. Conclusion & recommandations

Synthèse (ce qui compte vraiment)

Signaux les plus informatifs

- **Catégorielles très discriminantes** : international, mismatch, tranche 00–03
- **Numériques majeures** : device trust (↓), vélocité 24h (↑)
- **Secondaires** : âge (faible), catégorie marchand (faible bivarié, utile via interactions)

Choix du modèle selon l'usage

Scoring / priorisation : `INTER_unw` (PR AUC=0.8243, Brier=0.0052, ECE=0.004).
Décision (F1) : `STEP_unw` (F1=0.7869) mais seuil élevé (0.93).

Limites & next steps

Points d'attention

- **Calibration** : slope faible (0.437) $\Rightarrow$ probas trop extrêmes $\Rightarrow$ recalibration recommandée.
- **Quasi-séparation** possible (OR énormes) $\Rightarrow$ tester régularisation / Firth.
- **Seuil** : doit refléter coût FP/FN et capacité d'investigation (pas seulement F1).

Recommandation finale

Déployer **INTER_unw** pour **ranking** (tri des alertes), puis fixer un seuil opérationnel (ou top-K) et **recalibrer** si l'on veut des probabilités exploitables.