UFR - Mathématiques et Applications

Projet d'Analyse des Données

Master 2

Spécialité : Ingénierie Mathématique

Option : Ingénierie Financière et Modèles Aléatoires

Thème

Détection de fraude par carte bancaire : analyse statistique et modélisation supervisée sur données transactionnelles

Réalisé par :

Francky Roosevelt PETNGA TCHAKOUNTEU

Junwen XIAO

Antoine CHANEL

Achour AIT ARAB

Promotion 2025/2026

Introduction

Ce projet porte sur la **détection de fraude à la carte bancaire** à partir d'un jeu de données de **10 000 transactions** et d'une cible binaire `is_fraud` (`Legit` vs `Fraud`). La fraude étant **rare** (151 fraudes, soit **1.51%**), la difficulté principale n'est pas seulement d'obtenir une bonne précision globale, mais de construire un **scoring probabiliste** capable de **prioriser correctement** les transactions à risque (classement) tout en gardant des probabilités **exploitables** (calibration).

L'objectif est donc double : (i) **maximiser la détection** des fraudes (en privilégiant des métriques adaptées aux classes rares, notamment PR AUC), et (ii) produire un modèle **interprétable** et cohérent métier, en identifiant clairement les facteurs qui augmentent le risque.

Plan d'expérimentation

1. **Préparation & qualité des données**
   - Contrôles : absence de NA, absence de doublons, typage `factor`.
   - Construction de `hour_group` (6 tranches) pour capter un effet temporel non linéaire.
   - Transformation robuste du montant : `log_amount` $= \log(1 +$ `amount`$)$ (puis suppression de `amount`).
2. **Exploration statistique (EDA)**
   - Univarié : distributions, asymétries, outliers.
   - Bivarié vs `is_fraud` : descriptifs par groupe + tests (Welch/Wilcoxon pour numériques ; χ^2/Fisher, OR, Cramér V pour catégorielles).
3. **Protocole d'évaluation fiable (fraude rare)**
   - Split **stratifié** 80/20 (seed=123) afin de conserver le taux de fraude : $\approx 1.5\%$ train et test.
   - Deux stratégies : **unweighted** (baseline) vs **weighted** (poids $\approx$ ratio Legit/Fraud du train).
4. **Modélisation (6 modèles de régression logistique)**
   - `MAIN` : effets principaux (modèle interprétable de référence).
   - `INTER` : + non-linéarités (quadratiques) + interactions ciblées (métier).
   - `STEP` : sélection automatique stepwise AIC dans un espace enrichi (interactions à deux facteurs).
   - Chaque famille en **unweighted** et **weighted** $\Rightarrow$ 6 modèles comparés.
5. **Mesures et critères de sélection (alignés usage "scoring")**
   - **Ranking** : PR AUC (prioritaire) + ROC AUC.
   - **Qualité probabiliste** : Brier, calibration (intercept/slope), ECE (10 bins).
   - **Décision** : seuil optimal F1 (grille) + matrice de confusion + balanced accuracy.
   - **Interprétation** : OR, IC 95%, p-values (top facteurs de risque).

Chapitre 1

Traitement de la base de données

1.1 Credit Card Fraud Detection Dataset

Ce jeu de données regroupe **10 000 transactions** de carte bancaire, construit pour la recherche et l'expérimentation en **détection de fraude**. Les données sont **synthétiques** (sans informations clients réelles) et reproduisent un contexte réaliste où la fraude constitue une **classe rare**, situation typique des systèmes financiers.

1.2 Objectif

L'objectif est un problème de **classification binaire** : prédire, à partir des caractéristiques d'une transaction, si celle-ci est **frauduleuse** (`is_fraud = 1`) ou **légitime** (`is_fraud = 0`).

1.3 Dictionnaire des variables

Variable	Description
`transaction_id`	Identifiant unique de la transaction.
`amount`	Montant de la transaction.
`transaction_hour`	Heure de la transaction (0–23).
`merchant_category`	Catégorie du marchand (variable qualitative).
`foreign_transaction`	Transaction internationale (0 = non, 1 = oui).
`location_mismatch`	Incohérence entre facturation et lieu de transaction (0/1).
`device_trust_score`	Score de confiance du dispositif (0–100).
`velocity_last_24h`	Nombre de transactions sur les dernières 24 heures.
`cardholder_age`	Âge du porteur de carte (années).
`is_fraud`	**Variable cible** : 0 = transaction légitime, 1 = transaction frauduleuse.

Table 1.1 – Description des variables du *Credit Card Fraud Detection Dataset*.

1.4 Contrôles de qualité et préparation des variables

Cette étape a pour but de garantir que le jeu de données est **fiable** et **correctement typé** avant l'analyse exploratoire et l'entraînement des modèles. Concrètement, nous vérifions l'absence de valeurs manquantes et de doublons, puis nous convertissons certaines variables dans un format adapté à leur nature (catégorielle vs. numérique).

1.4.1 Absence de valeurs manquantes :

Les valeurs manquantes (`NA`) peuvent biaiser les statistiques descriptives (moyennes, distributions), réduire la taille effective de l'échantillon (suppression automatique de lignes) et provoquer des erreurs dans certains algorithmes. Nous calculons le nombre total de valeurs manquantes avec `sum(is.na(df))` et obtenons **0**. Le jeu de données est donc complet : aucune stratégie d'imputation ou de suppression de lignes n'est requise.

1.4.2 Absence de doublons sur l'identifiant :

L'identifiant `transaction_id` est supposé être unique. Des doublons entraîneraient un comptage multiple de certaines transactions, ce qui fausserait les taux (par exemple le taux de fraude) et introduirait un biais lors de l'apprentissage.
Le contrôle `sum(duplicated(df$transaction_id))` renvoie **0**, confirmant que chaque transaction est représentée une seule fois.

1.4.3 Conversion des variables catégorielles :

Plusieurs variables sont encodées sous forme `int` (`0/1`) ou `chr` alors qu'elles représentent des catégories. Les convertir en `factor` est essentiel pour éviter qu'elles soient interprétées comme des variables quantitatives (avec un ordre ou une distance arbitraire) et pour améliorer l'interprétabilité des résultats (tableaux, graphiques, coefficients). Ainsi :

- la variable cible `is_fraud` est transformée de `0/1` en `Legit/Fraud` afin de clarifier la tâche de classification ;
- `foreign_transaction` et `location_mismatch` deviennent `No/Yes` pour une lecture directe ;
- `merchant_category`, initialement en texte, est convertie en facteur car elle correspond à un ensemble fini de catégories (ici **5** modalités).

1.4.4 Regroupement de l'heure en tranches :

La variable `transaction_hour` (0–23) est une mesure temporelle dont l'effet est souvent non linéaire : les comportements de transaction peuvent différer nettement entre la nuit, le matin et le soir, sans que l'heure puisse être interprétée comme une quantité continue. Nous regroupons donc cette variable en **6** tranches (`00-03`, `04-07`, `08-11`, `12-15`, `16-19`, `20-23`) via `cut`, afin d'obtenir une variable `hour_group` plus robuste et plus interprétable.

Chapitre 2

Analyse Descriptive Univariée

L'objectif de cette analyse descriptive univariée est d'explorer en détail chaque variable de manière indépendante afin de mieux comprendre leur comportement et leurs caractéristiques. Nous nous intéresserons notamment à la distribution de chaque variable, en identifiant les mesures de tendance centrale (telles que la moyenne, la médiane), ainsi que la dispersion (écart-type, plage interquartile). Nous analyserons également la présence éventuelle de valeurs aberrantes ou d'anomalies qui pourraient influencer les résultats ultérieurs. Cette approche permet de clarifier la structure des données avant d'engager des analyses plus poussées, telles que des modèles prédictifs ou des tests statistiques, en garantissant ainsi une meilleure interprétation des résultats.

2.1 Montant de transaction

TABLE 2.1 – Synthèse de la variable `amount`.

Résumé numérique

Indicateur	**Valeur**
Ecart-type	175.39
Moyenne	175.95
Médiane [Q1 ; Q3]	122.10 [50.91; 242.48]
Min – Max	0 – 1471.04

Distribution (histogramme + boxplot)

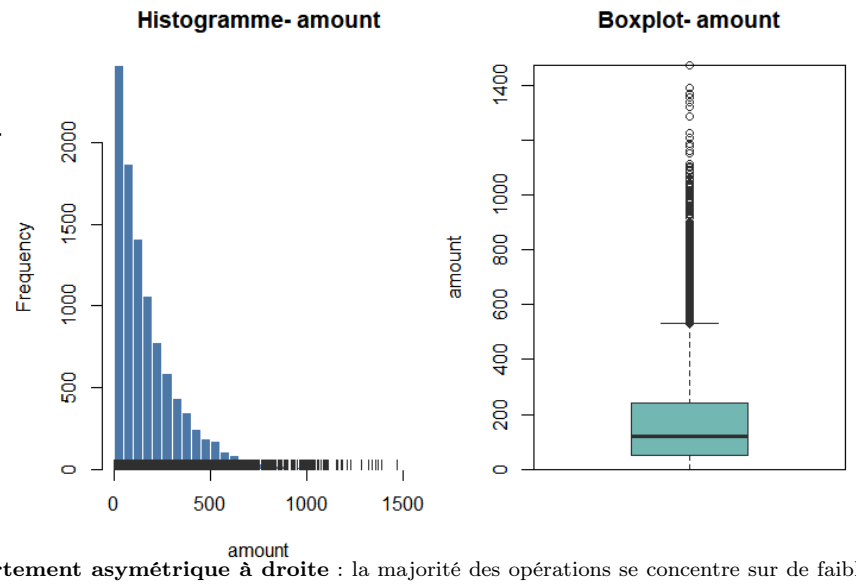

Interprétation : La distribution est **fortement asymétrique à droite** : la majorité des opérations se concentre sur de faibles montants, tandis qu'un nombre limité de transactions atteint des valeurs élevées (jusqu'à 1471). L'écart entre la moyenne (175.95) et la médiane (122.10) confirme cette asymétrie. Le boxplot met en évidence **de nombreux montants atypiques**, ce qui est plausible dans des données de paiement.

2.2 Score de confiance de l'appareil

TABLE 2.2 – Résumé numérique de la variable `device_trust_score`.

Résumé numérique

Indicateur	**Valeur**
Ecart-type	21.49
Moyenne	61.80
Médiane [Q1 ; Q3]	62 [43; 80]
Min – Max	25 – 99

Distribution (histogramme + boxplot)

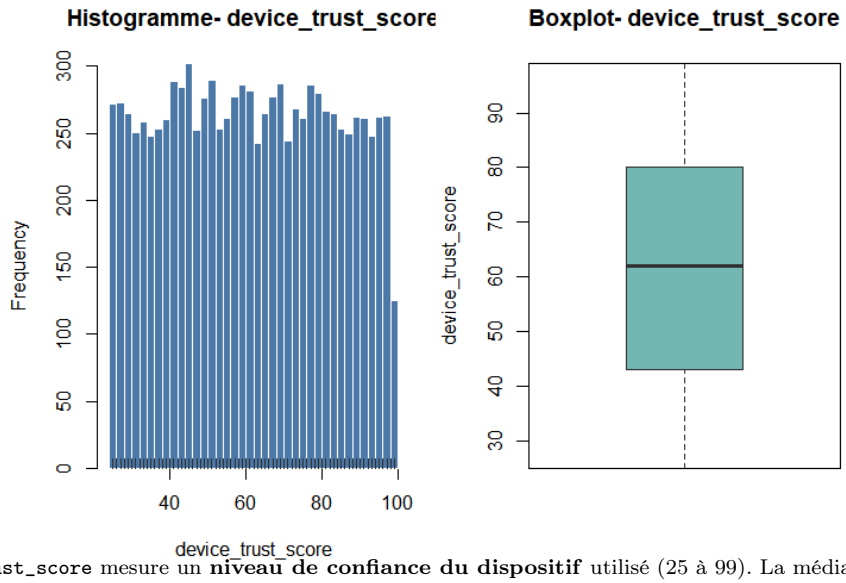

Interprétation : La variable `device_trust_score` mesure un **niveau de confiance du dispositif** utilisé (25 à 99). La médiane (62) et l'intervalle interquartile [43 ; 80] indiquent une population centrée sur des scores intermédiaires, avec une dispersion importante (ET = 21.49). Le boxplot ne montre pas d'extrêmes marqués, suggérant une variabilité régulière sur l'échantillon. Cette variable constitue un **indicateur continu potentiellement informatif** pour la suite.

2.3 Vélocité sur 24 heures

TABLE 2.3 – Résumé numérique de la variable `velocity_last_24h`.

Résumé numérique

Indicateur	**Valeur**
Ecart-type	1.43
Moyenne	2.01
Médiane [Q1 ; Q3]	2 [1; 3]
Min – Max	0 – 9

Distribution (histogramme + boxplot)

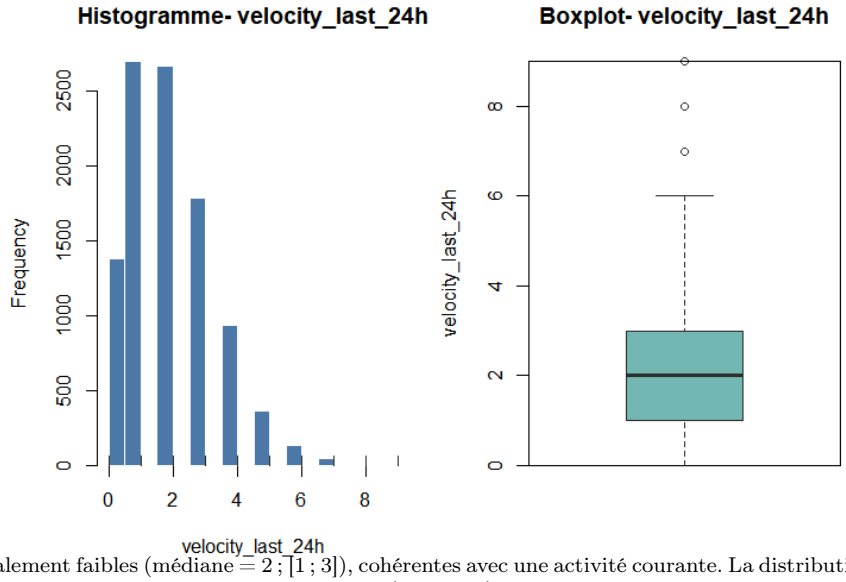

Interprétation : Les valeurs sont principalement faibles (médiane = 2 ; [1 ; 3]), cohérentes avec une activité courante. La distribution est **asymétrique à droite** : quelques observations atteignent des niveaux élevés (jusqu'à 9) et apparaissent comme atypiques. Ces niveaux de vélocité pourraient refléter des comportements plus intensifs, à investiguer en bivarié.

2.4 Age du porteur

TABLE 2.4 – Résumé numérique de la variable `cardholder_age`.

Résumé numérique

Indicateur	Valeur
Ecart-type	14.98
Moyenne	43.47
Médiane [Q1 ; Q3]	44 [30; 56]
Min – Max	18 – 69

Distribution (histogramme + boxplot)

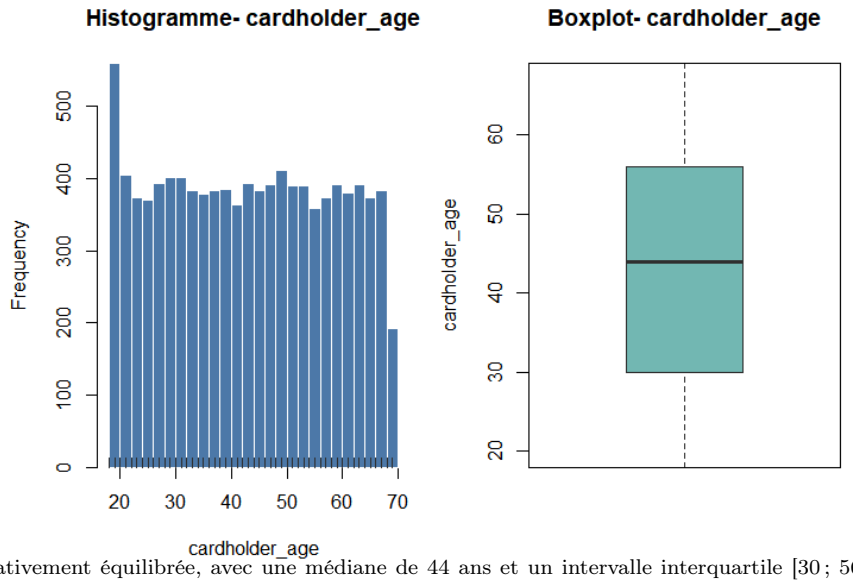

Interprétation : La distribution est relativement équilibrée, avec une médiane de 44 ans et un intervalle interquartile [30 ; 56]. La dispersion est modérée (ET = 14.98) et le boxplot ne met pas en évidence d'anomalies marquées. Cette variable apporte principalement une information de contexte socio-démographique.

2.5 Heure de transaction

TABLE 2.5 – Résumé des effectifs pour `transaction_hour`.

Résumé des effectifs

Indicateur	Valeur
Modalité la plus fréquente	14h : 458 (4.58%)
Modalité la moins fréquente	10h : 358 (3.58%)

Répartition par heure

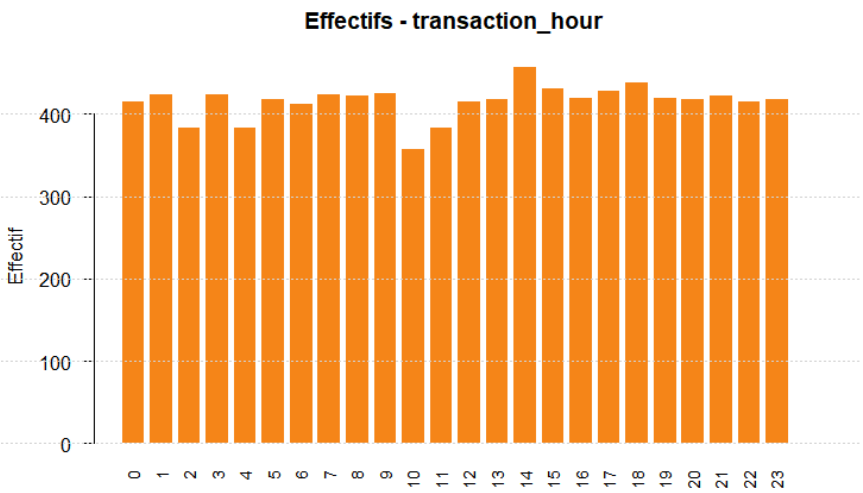

Interprétation : La répartition est globalement **homogène** sur la journée : chaque heure représente environ 3.6% à 4.6% des transactions. Cette structure suggère l'absence de concentration temporelle forte dans l'échantillon. L'heure reste néanmoins un facteur à tester en lien avec la fraude lors des analyses bivariées.

2.6 Catégorie du marchand

TABLE 2.6 – Répartition des transactions par `merchant_category`.

Répartition	
Catégorie	**Effectif (%)**
Food	2093 (20.93%)
Clothing	2050 (20.50%)
Travel	1990 (19.90%)
Grocery	1944 (19.44%)
Electronics	1923 (19.23%)

Répartition par catégorie

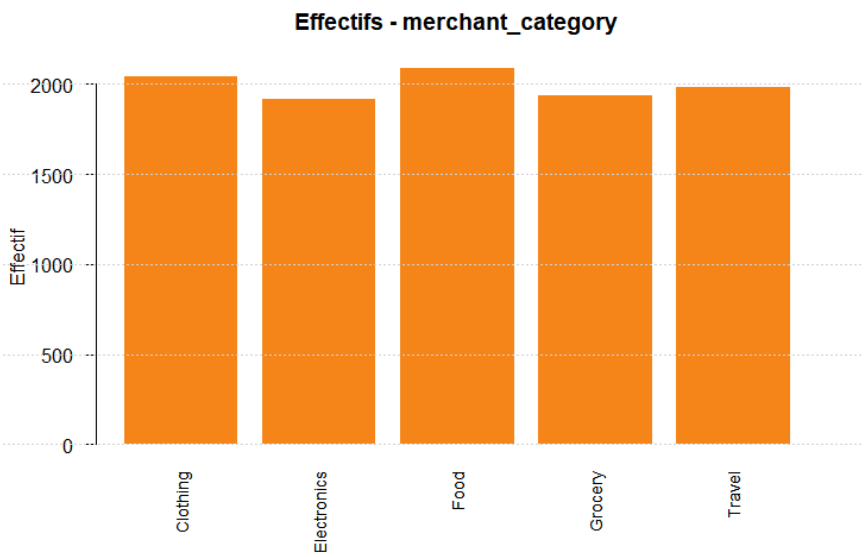

Interprétation : Les effectifs sont **bien équilibrés** (environ 19% à 21% par catégorie), ce qui réduit le risque qu'une modalité domine l'analyse descriptive. Cette répartition est favorable pour comparer ensuite les taux de fraude entre catégories. Aucune catégorie ne se distingue fortement en univarié.

2.7 Transaction internationale

TABLE 2.7 – Répartition de `foreign_transaction`.

Répartition	
Modalité	**Effectif (%)**
No	9022 (90.22%)
Yes	978 (9.78%)

National vs international

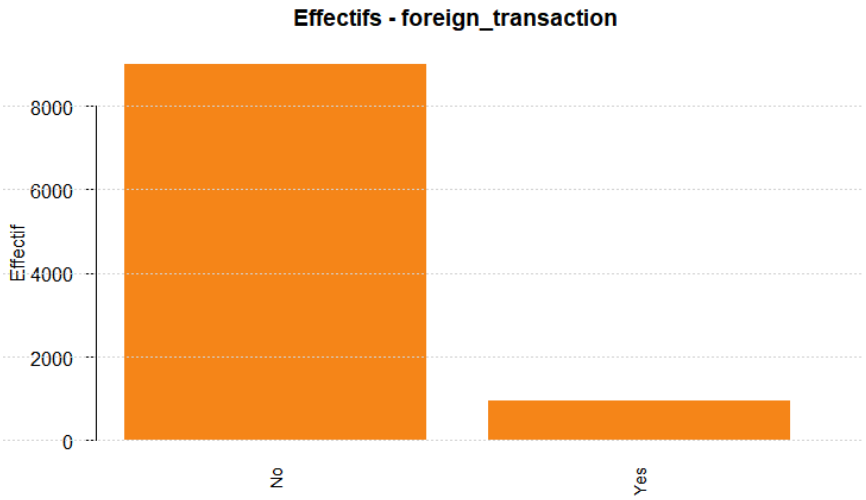

Interprétation : Les transactions internationales représentent 9.78% des observations, ce qui est cohérent avec un usage généraliste. Cette modalité reste minoritaire et constitue un signal de contexte intéressant à confronter ensuite au statut de fraude.

2.8 Incohérence de localisation

TABLE 2.8 – Répartition de `location_mismatch`.

Répartition	**Répartition de l'incohérence géographique**
Modalité	**Effectif (%)**
No	9143 (91.43%)
Yes	857 (8.57%)

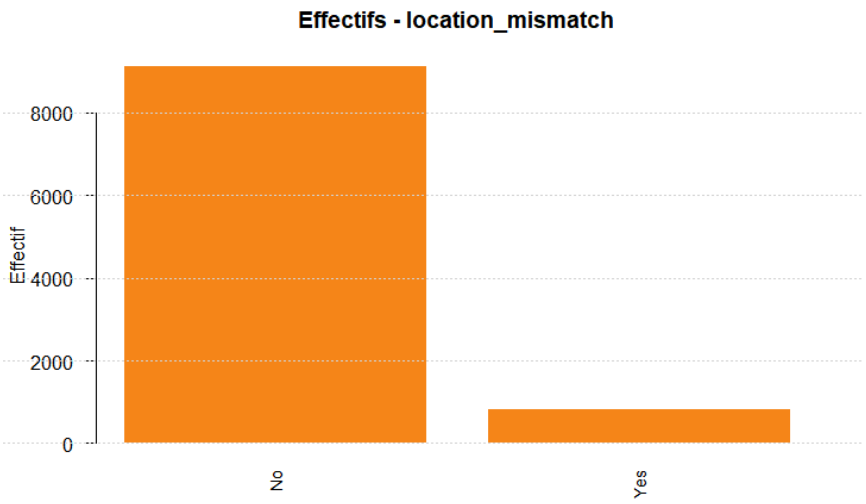

Interprétation : Les cas d'incohérence sont rares (8.57%), ce qui est cohérent avec une majorité de transactions normales. Cette variable correspond à un **signal de risque explicite** et sera particulièrement pertinente à tester en association avec la fraude.

2.9 Variable cible (is_fraud)

TABLE 2.9 – Répartition de la variable cible `is_fraud`.

Répartition	**Déséquilibre des classes**
Classe	**Effectif (%)**
Legit	9849 (98.49%)
Fraud	151 (1.51%)

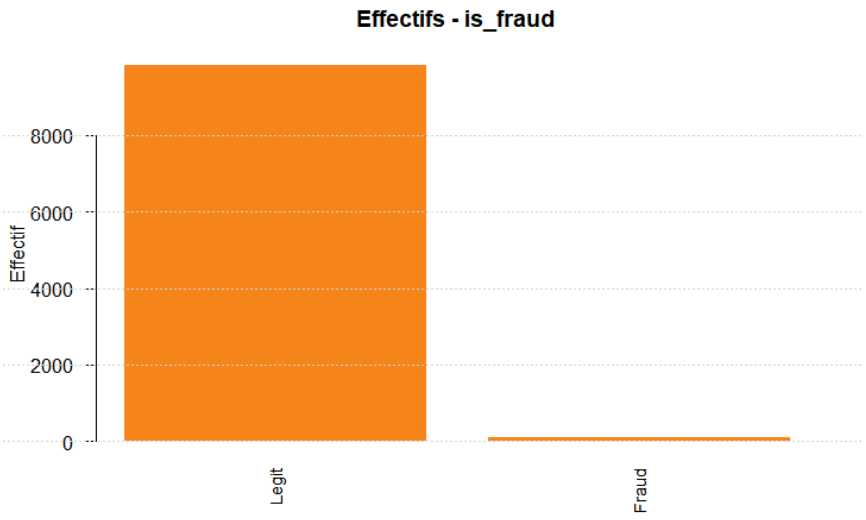

Interprétation : La variable `is_fraud` constitue la **cible** de l'étude. La fraude est **très minoritaire** (1.51%), ce qui entraîne un fort déséquilibre de classes.

Chapitre 3

Analyse bivariée vs `is_fraud`

3.1 Objectif et démarche

L'objectif de cette analyse bivariée est d'identifier, *variable par variable*, les facteurs associés à la fraude (`is_fraud`) et d'évaluer la nature de cette association (*différence de moyennes/positions* pour les numériques, *dépendance* pour les catégorielles).

On compare deux groupes indépendants :

$$G \in \{\text{Legit},\ \text{Fraud}\}, \qquad n_L = 9849, \quad n_F = 151, \quad n = n_L + n_F = 10000,$$

avec une fraude très minoritaire (1.51%). Cette asymétrie impose une lecture prudente : des tests peuvent être très sensibles, et il est essentiel de compléter les p-values par (i) des intervalles de confiance, (ii) des mesures d'association adaptées (OR, Cramér V), et (iii) une interprétation *métier*.

Règle de décision. On fixe $\alpha = 0.05$. Pour un test donné, si p-value $< \alpha$, on rejette H_0.

3.2 Variables numériques : descriptifs par groupe

Table 3.1 – Statistiques descriptives par groupe (variables numériques).

Variable	Groupe	Moy.	Sd	Méd.	IQR	Min–Max
`amount`	Legit	175.333	173.9868	122.11	190.660	0.00–1471.04
`amount`	Fraud	216.183	248.1205	118.94	300.165	0.11–1185.07
`device_trust_score`	Legit	62.16580	21.35110	62	36.0	25–99
`device_trust_score`	Fraud	37.86755	16.17928	32	9.5	25–99
`velocity_last_24h`	Legit	1.990557	1.415366	2	2	0–9
`velocity_last_24h`	Fraud	3.205298	1.953861	3	3	0–7
`cardholder_age`	Legit	43.46979	14.98722	44	26	18–69
`cardholder_age`	Fraud	43.39735	14.49095	44	24	18–69

3.3 Outils statistiques (conditions d'application et hypothèses)

Table 3.2 – Conditions d'application et hypothèses des tests/indicateurs utilisés.

Test / indicateur	**Hypothèses (H_0 vs H_1)**	**Conditions d'application (principales)**
Shapiro–Wilk (normalité)	$H_0 : X \sim \mathcal{N}(\mu, \sigma^2)$ vs $H_1 : X$ n'est pas normale.	Échantillon univarié, indépendant. En pratique sous R : $3 \leq n \leq 5000$.
TCL / CLT (justification inférence sur $\bar{X}$)	$\bar{X}$ est approximativement normale quand n est grand.	Règle pratique : $n \geq 30$ par groupe.
Brown–Forsythe (Levene médiane)	$H_0 : \sigma_L^2 = \sigma_F^2$ vs $H_1 : \sigma_L^2 \neq \sigma_F^2$.	Groupes indépendants. Test robuste en non-normalité (utilise les écarts à la médiane).
Welch t-test (différence de moyennes)	$H_0 : \mu_L = \mu_F$ vs $H_1 : \mu_L \neq \mu_F$.	Groupes indépendants. Recommandé si variances inégales et/ou tailles différentes ; acceptable si TCL applicable.
Wilcoxon / Mann–Whitney (2 groupes)	H_0 : distributions identiques (au sens de la position/rangs) vs H_1 : différence de position/distribution.	Deux échantillons indépendants. Ne requiert pas la normalité ; basé sur les rangs (robuste aux outliers).
χ^2 d'indépendance (table $r \times c$)	H_0 : indépendance entre variables vs H_1 : dépendance/association.	Observations indépendantes. Effectifs attendus suffisants (règle pratique : attendus > 5).
Fisher exact (2x2)	H_0 : indépendance (2x2) vs H_1 : association.	Table 2x2. Recommandé si effectifs attendus faibles (alternative au χ^2).
Cramér V (taille d'association)	Mesure d'intensité d'association : $V \in [0, 1]$ (pas un test).	S'appuie sur χ^2 et une table $r \times c$.
Odds Ratio (OR) (2x2)	Mesure d'association : OR $> 1 \Rightarrow$ odds plus élevées dans la modalité d'intérêt (pas un test).	Table 2x2. Interprétation dépend de la convention.

3.3.1 Variables numériques : tests (p-values et intervalles de confiance)

Table 3.3 – Synthèse des tests pour les variables numériques (Welch + Wilcoxon).

Variable	**Welch**	**Wilcoxon**	**Hétéroscéd. BF**
`amount`	0.04561 [-80.892 ; -0.808]	0.572 [-23.4 ; 12.38]	0.008596
`device_trust_score`	1.154×10^{-40} [21.663 ; 26.933]	2.54×10^{-43} [22 ; 29]	1.429×10^{-12}
`velocity_last_24h`	2.664×10^{-12} [-1.53 ; -0.899]	8.807×10^{-15} [-2 ; -1]	9.053×10^{-12}
`cardholder_age`	0.9515 [-2.276 ; 2.421]	0.9558 [-2 ; 3]	0.2771

3.3.2 Variables catégorielles : tests et mesures d'association

TABLE 3.4 – Synthèse des tests pour les variables catégorielles (χ^2, Cramér V, OR si 2x2).

Variable	p-value (χ^2)	Cramér V	OR (IC 95%) si 2x2
`hour_group`	4.801×10^{-95}	0.212	–
`merchant_category`	0.1918	0.025	–
`foreign_transaction`	6.803×10^{-77}	0.186	11.869 [8.446 ; 16.723]
`location_mismatch`	4.63×10^{-67}	0.173	10.518 [7.47 ; 14.785]

3.4 Variables numériques : lecture graphique et interprétation

3.4.1 `device_trust_score` : un signal majeur (confiance appareil)

Constat descriptif. Le score de confiance est nettement plus faible en fraude : médiane 32 contre 62, et moyenne 37.87 contre 62.17 .

Conditions et tests. Shapiro rejette la normalité dans les deux groupes (p-values $\ll 0.05$), ce qui est attendu pour une variable *bornée* (25–99). Le test de Brown–Forsythe est significatif ($p = 1.429 \times 10^{-12}$) : les dispersions diffèrent, justifiant Welch. Les deux tests (Welch et Wilcoxon) concluent à une différence **hautement significative**.

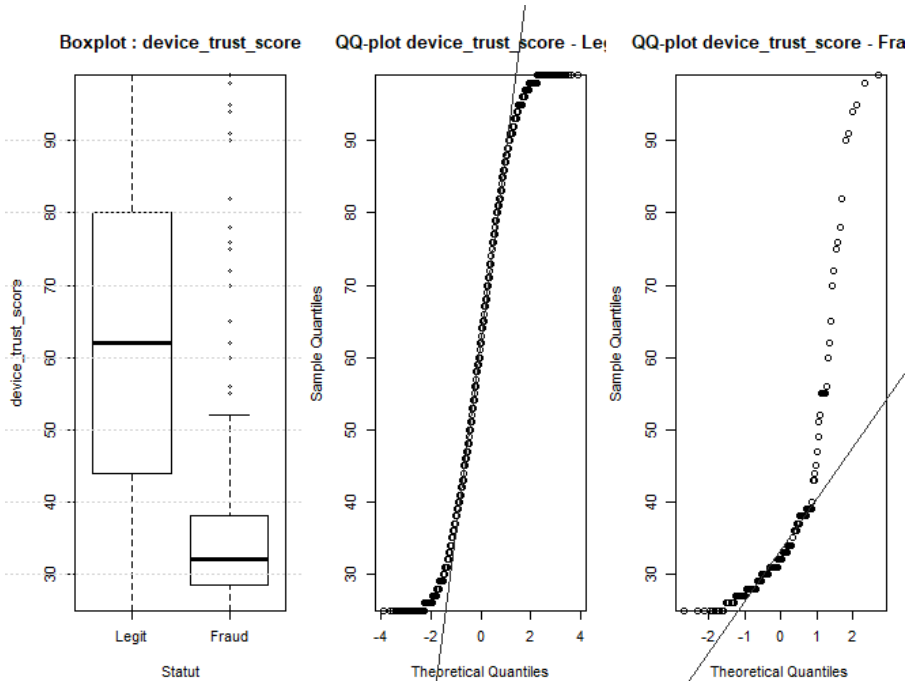

FIGURE 3.1 – Boxplot et QQ-plots — `device_trust_score` vs `is_fraud`.

Interprétation métier. La fraude est associée à un score de confiance nettement plus bas. C'est cohérent : des dispositifs « peu fiables » (nouveau device, empreinte instable, comportement atypique) sont plus souvent liés aux transactions frauduleuses. En modélisation, cette variable doit être considérée comme **prioritaire**.

3.4.2 `velocity_last_24h` : activité accrue en fraude

Constat descriptif. Les fraudes présentent une vélocité plus élevée : médiane 3 vs 2 et moyenne 3.21 vs 1.99.

Conditions et tests. La non-normalité est attendue (variable discrète de comptage : valeurs en paliers). Brown–Forsythe est très significatif ($p = 9.053 \times 10^{-12}$), d'où l'intérêt de Welch. Welch et Wilcoxon convergent fortement ($p \ll 10^{-10}$) et l'IC du shift HL est $[-2; -1]$ pour $\bar{X}_L - \bar{X}_F$ (donc `Fraud` est globalement plus élevé).

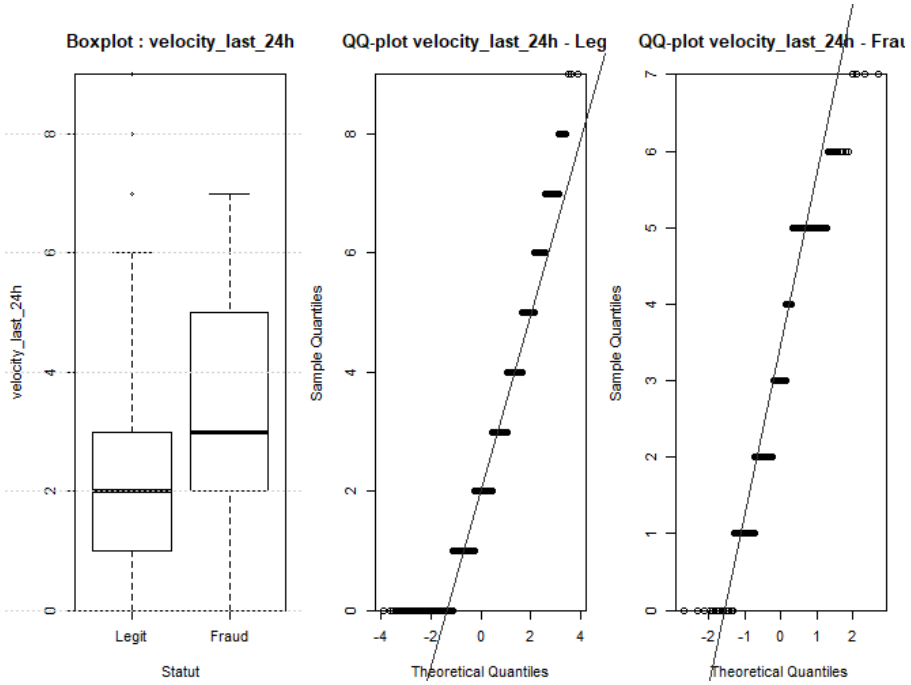

FIGURE 3.2 – Boxplot et QQ-plots — `velocity_last_24h` vs `is_fraud`.

Interprétation métier. La fraude s'accompagne d'un rythme transactionnel plus intense sur 24h. C'est typique des scénarios d'attaque (multiples tentatives rapprochées, tests de cartes, rafales). Cette variable est **très discriminante** et doit être exploitée (éventuellement avec des transformations ou des seuils).

3.4.3 `amount` : signal faible et dépendant de la queue de distribution

Constat descriptif. Les médianes sont très proches (122.11 vs 118.94), mais la moyenne est plus élevée en fraude (216.18 vs 175.33) avec une dispersion plus forte (sd 248.12 vs 173.99). Le boxplot et les QQ-plots suggèrent une **forte asymétrie à droite** et des valeurs extrêmes.

Tests : divergence Welch vs Wilcoxon. Welch détecte une différence de moyennes au seuil 5% ($p = 0.04561$, IC 95% de $\bar{X}_L - \bar{X}_F = [-80.892; -0.808]$). En revanche, Wilcoxon n'est pas significatif ($p = 0.572$, HL $[-23.4; 12.38]$).

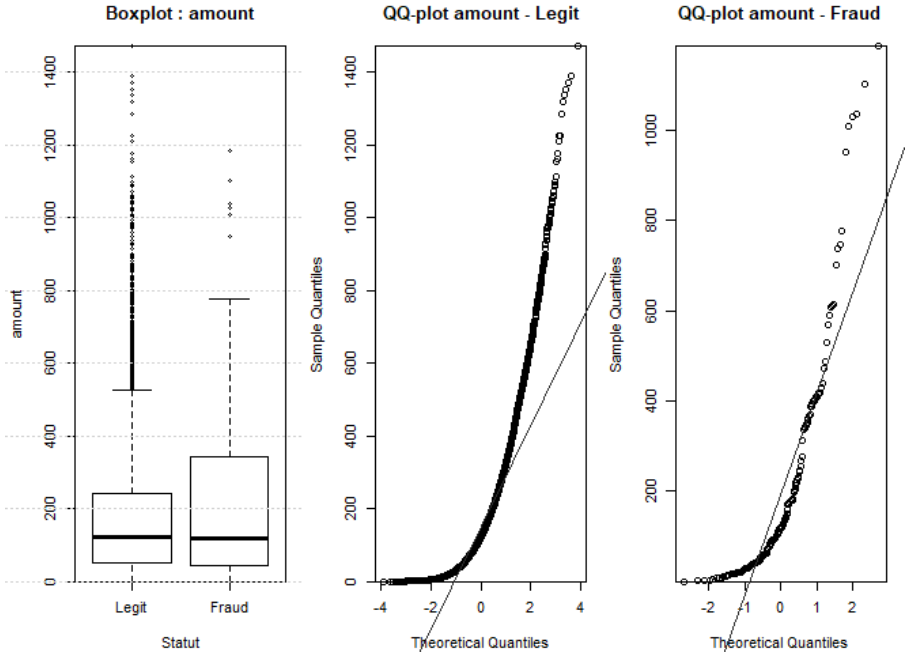

FIGURE 3.3 – Boxplot et QQ-plots — `amount` vs `is_fraud`.

Interprétation claire de la divergence.

- **Centre de distribution similaire** : médianes proches ⇒ pas de déplacement global des rangs.
- **Queue plus lourde côté fraude** : quelques montants élevés peuvent augmenter la *moyenne* sans modifier fortement la médiane.
- **Conclusion opérationnelle** : `amount` porte un signal *faible* en bivarié, plutôt situé dans les **valeurs élevées** (comportement « extrême ») et donc potentiellement instable.

Recommandation (exploitation feature). Pour stabiliser l'information : transformations ($\log(1 + \texttt{amount})$), indicateurs de quantiles (montant > Q90/Q95), ou interactions (montant élevé × transaction étrangère / mismatch).

3.4.4 `cardholder_age` : absence de signal bivarié

Constat descriptif. Les deux groupes sont quasi identiques (moyennes 43.47 vs 43.40 ; médiane 44 dans les deux cas). Brown–Forsythe n'indique pas de variances différentes ($p = 0.2771$).

Tests. Welch ($p = 0.9515$) et Wilcoxon ($p = 0.9558$) sont non significatifs, avec des IC englobant 0.

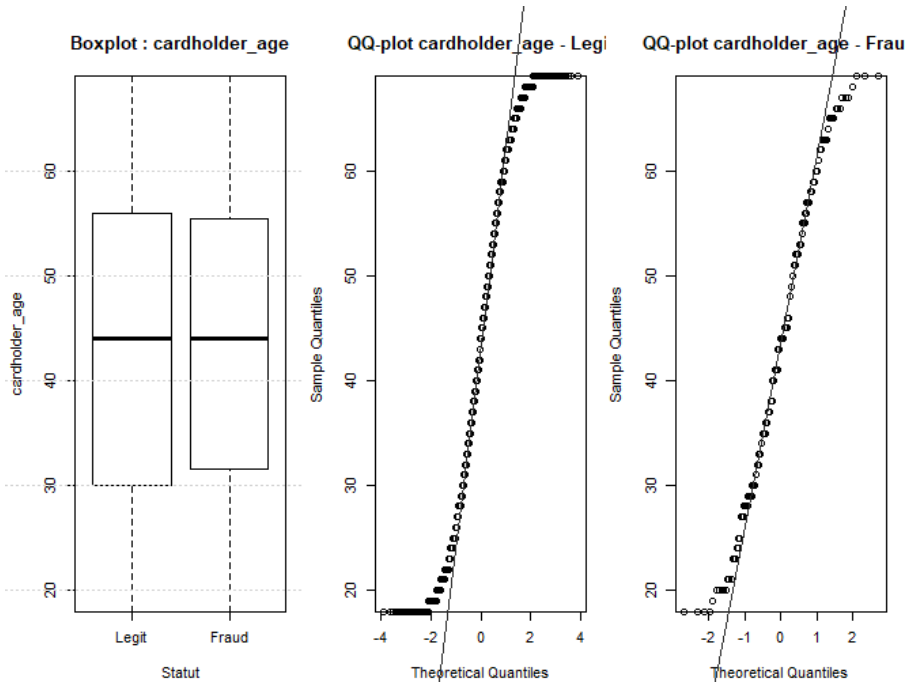

FIGURE 3.4 – Boxplot et QQ-plots — `cardholder_age` vs `is_fraud`.

Interprétation métier. **L'âge ne discrimine pas** fraude vs légitime dans cet échantillon. Au mieux, il pourrait intervenir via des *interactions* en multivarié, mais isolément il n'apporte pas de pouvoir discriminant.

3.5 Variables catégorielles : taux de fraude, tests et interprétation

3.5.1 `foreign_transaction` : un facteur de risque très fort

TABLE 3.5 – Table de contingence et taux de fraude — `foreign_transaction`.

Modalité	Legit	Fraud	Taux fraude
No	8953	69	0.76%
Yes	896	82	8.38%

Lecture descriptive. Une transaction étrangère multiplie le taux de fraude d'environ 0.76% à 8.38% : l'écart est massif.

Test et intensité. Le χ^2 conclut à une association extrêmement significative ($p = 6.803 \times 10^{-77}$). Cramér $V = 0.186$ indique une association *faible à modérée* en intensité globale (effet « concentré » sur une modalité), tandis que l'OR est très élevé : 11.869 [8.446; 16.723].

Interprétation métier. **Les transactions internationales constituent un marqueur de risque majeur.** Cela peut refléter : usage inhabituel du porteur, transactions transfrontalières opportunistes, ou attaques automatisées via canaux spécifiques.

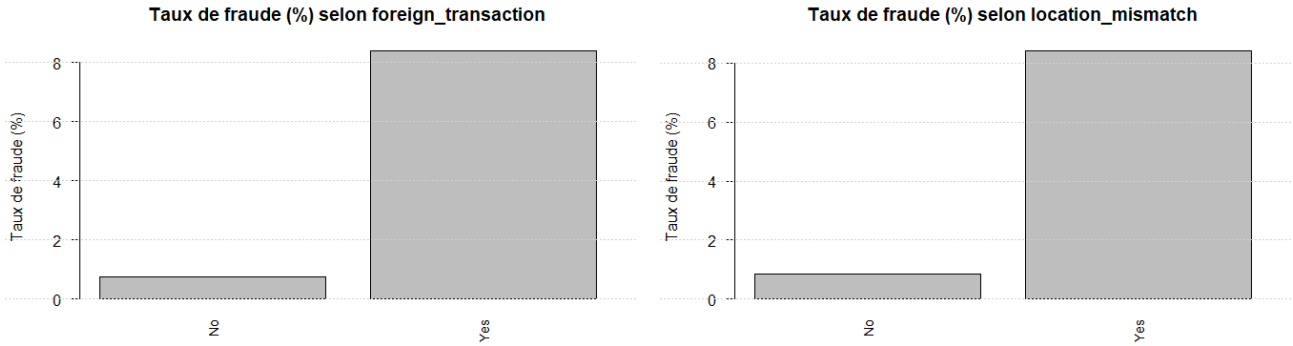

(a) Taux de fraude selon `foreign_transaction`.

(b) Taux de fraude selon `location_mismatch`.

FIGURE 3.5 – Taux de fraude (%) — variables binaires (2x2).

3.5.2 `location_mismatch` : incohérence géographique très discriminante

TABLE 3.6 – Table de contingence et taux de fraude — `location_mismatch`.

Modalité	Legit	Fraud	Taux fraude
No	9064	79	0.86%
Yes	785	72	8.40%

Lecture descriptive. Le mismatch multiplie le taux de fraude de 0.86% à 8.40% : écart très net, comparable à `foreign_transaction`.

Test et intensité. Association hautement significative ($p = 4.63 \times 10^{-67}$), Cramér $V = 0.173$ et OR=10.518 [7.47; 14.785].

Interprétation métier. Signal de risque « explicite » : une incohérence de localisation peut indiquer vol d'identifiants/compromission, usage à distance, ou contournement des contrôles géographiques.

3.5.3 `hour_group` : effet temporel concentré sur 00–03

TABLE 3.7 – Taux de fraude par tranche horaire — `hour_group`.

Tranche	Legit	Fraud	Taux fraude
00–03	1531	121	7.32%
04–07	1636	5	0.30%
08–11	1586	7	0.44%
12–15	1722	5	0.29%
16–19	1703	7	0.41%
20–23	1671	6	0.36%

Lecture descriptive. La tranche **00–03** présente un taux de fraude **très supérieur** (7.32%) alors que toutes les autres tranches restent autour de 0.29%–0.44%. Le signal est donc **fort mais concentré**.

Test et intensité. Le χ^2 est extrêmement significatif ($p = 4.801 \times 10^{-95}$), avec Cramér $V = 0.212$, ce qui est cohérent avec un effet structuré par une modalité dominante.

Interprétation métier. Cette sur-fraude nocturne peut traduire : (i) des attaques automatisées en heures creuses, (ii) des contraintes opérationnelles différentes (moins de contrôles), (iii) des profils d'usage spécifiques. En pratique, `hour_group` est une **feature utile** (voire une règle) centrée sur 00–03.

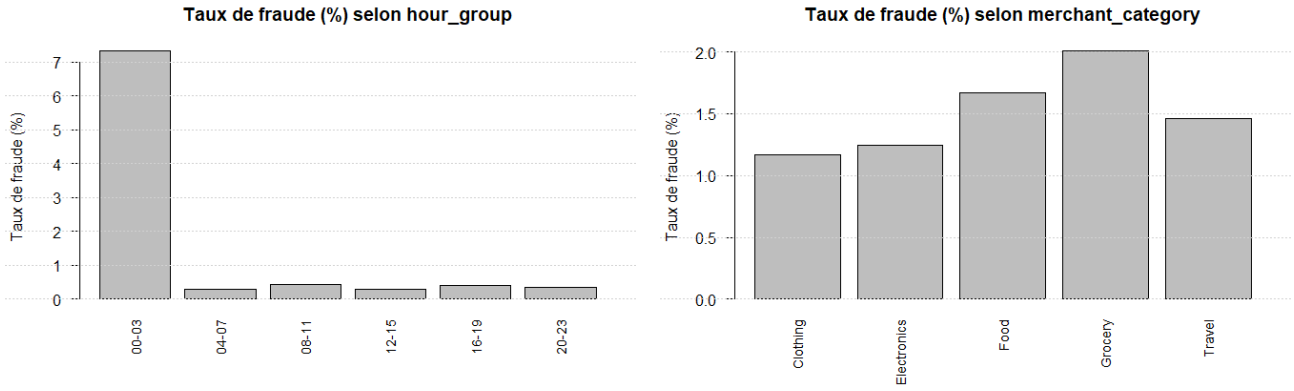

(a) Taux de fraude selon `hour_group`.

(b) Taux de fraude selon `merchant_category`.

FIGURE 3.6 – Taux de fraude (%) — variables multi-modalités.

3.5.4 `merchant_category` : pas d'association bivariée robuste

TABLE 3.8 – Taux de fraude par catégorie — `merchant_category`.

Catégorie	Legit	Fraud	Taux fraude
Clothing	2026	24	1.17%
Electronics	1899	24	1.25%
Food	2058	35	1.67%
Grocery	1905	39	2.01%
Travel	1961	29	1.46%

Lecture descriptive. Les taux varient de 1.17% à 2.01%, sans rupture majeure.

Test et intensité. Le χ^2 n'est pas significatif au seuil 5% ($p = 0.1918$) et Cramér $V = 0.025$ indique une association négligeable.

Interprétation métier. Isolément, la catégorie marchand n'explique pas la fraude de manière robuste. Elle peut néanmoins devenir utile en multivarié (interactions : catégorie $\times$ transaction étrangère, catégorie $\times$ heure nocturne, etc.).

3.6 Synthèse opérationnelle et priorisation

Variables les plus informatives (bivarié). Sur la base des tableaux 3.3 et 3.4 et des figures :

- **Très fortes associations** : `device_trust_score` (Fraud ↓), `velocity_last_24h` (Fraud ↑), `foreign_transaction` (OR ≈ 11.9), `location_mismatch` (OR ≈ 10.5), `hour_group` (pic `00-03`).
- **Signal faible / instable** : `amount` (différence surtout en queue ; Welch significatif mais Wilcoxon non).
- **Peu informatives en bivarié** : `cardholder_age` et `merchant_category`.

3.7 Conclusion

L'analyse bivariée met en évidence des signaux cohérents et exploitables :

- **Risque très élevé** : transactions **étrangères** et **mismatch** de localisation (OR ≈ 10–12).
- **Comportemental** : vélocité 24h plus forte en fraude.
- **Confiance device** : score beaucoup plus bas en fraude, signal majeur.
- **Temporalité** : sur-risque concentré sur 00–03.

À l'inverse, l'âge du porteur et la catégorie marchand n'apportent pas de différence bivariée robuste. Le montant (`amount`) est à exploiter via transformations/quantiles et interactions plutôt que comme simple variable linéaire.

Chapitre 4

Régression logistique et évaluation des modèles

4.1 Objectif, données et protocole

L'objectif est de construire un classifieur probabiliste $P(\texttt{Fraud} \mid \mathbf{x})$ et de comparer **six variantes** de régression logistique sur un **split stratifié** (fraude rare).

Jeu de données et déséquilibre. Sur $n = 10000$ transactions, la fraude représente 1.51% (151 fraudes). Le split stratifié (80/20) conduit à un test de taille $n_{\text{test}} = 2001$ dont 31 fraudes ($\approx 1.55\%$).

Prétraitement clé. Le montant est remplacé par une variable plus robuste :

$$\texttt{log_amount} = \log(1 + \texttt{amount}),$$

puis `amount` est supprimée (réduction de l'asymétrie et de l'influence des extrêmes).

Poids de classe (option "weighted"). Pour les modèles pondérés, les observations `Fraud` reçoivent un poids w égal au ratio (Legit/Fraud) du train (environ ~ 66), afin de réduire le biais vers la classe majoritaire.

4.2 Modèle : régression logistique

On note $Y \in \{0, 1\}$ avec $Y = 1$ pour `Fraud`. La régression logistique modélise :

$$\pi(\mathbf{x}) = P(Y = 1 \mid \mathbf{x}) = \sigma(\eta(\mathbf{x})) = \frac{1}{1 + \exp(-\eta(\mathbf{x}))}, \qquad \eta(\mathbf{x}) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j.$$

Équivalent en **log-odds** :

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j.$$

L'interprétation standard : à covariables fixes, une augmentation de x_j d'une unité multiplie les *odds* par

$$\mathrm{OR}_j = \exp(\beta_j).$$

En présence d'**interactions**, un effet principal (ex. `foreign_transactionYes`) s'interprète *au niveau de référence* des variables avec lesquelles il interagit.

4.3 Familles de modèles comparées

Table 4.1 – Les 6 modèles entraînés (structure).

Modèle	Structure
`MAIN_unw` / `MAIN_w`	Effets principaux : `log_amount`, `device_trust_score`, `velocity_last_24h`, `cardholder_age` + catégorielles (`merchant_category`, `foreign_transaction`, `location_mismatch`, `hour_group`).
`INTER_unw` / `INTER_w`	+ **Non-linéarités** (termes quadratiques) et + **interactions ciblées** (ex. `foreign_transaction:location_mismatch`, `device_trust_score:velocity_last_24h`, etc.).
`STEP_unw` / `STEP_w`	Sélection **stepwise AIC** (direction *both*) à partir de `MAIN` avec un espace de recherche incluant toutes les interactions à deux facteurs (scope $(\cdot)^2$).

4.4 Mesures d'évaluation

Table 4.2 – Métriques utilisées : définition et lecture.

Métrique	Définition / interprétation
ROC (TPR vs FPR)	Pour un seuil t, prédire $\hat{Y} = 1$ si $\hat{p} \geq t$. TPR= $\frac{TP}{TP+FN}$, FPR= $\frac{FP}{FP+TN}$. La courbe ROC trace (FPR,TPR) en balayant t.
ROC AUC	Aire sous la ROC (discrimination globale). Valeur proche de 1 : très bon classement des fraudes au-dessus des légitimes.
PR (Precision vs Recall)	Precision= $\frac{TP}{TP+FP}$, Recall= $\frac{TP}{TP+FN}$. Plus informative que ROC quand la classe positive est rare.
PR AUC	Aire sous la PR (ici intégration trapèzes). Résume la qualité *côté fraude* sur tous les seuils.
Brier score	Brier $= \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{p}_i)^2$. Plus petit = meilleures probabilités (calibration globale + discrimination).
Calibration (intercept/slope)	Régression $y \sim \text{logit}(\hat{p})$. Idéal : intercept ≈ 0, slope ≈ 1. Slope < 1 suggère des probabilités trop extrêmes (sur-confiance).
ECE (Expected Calibration Error)	Découpage en K bins : ECE $= \sum_{k=1}^{K} \frac{n_k}{n} \left\lvert \text{acc}(k) - \text{conf}(k) \right\rvert$. Plus petit = meilleure calibration (dépend du binning).
F1 et Balanced Accuracy	$F1 = \frac{2PR}{P+R}$. BalancedAcc= $\frac{\text{Recall+Specificity}}{2}$ avec Specificity= $\frac{TN}{TN+FP}$.

4.5 Résultats comparatifs (test)

4.5.1 Comparaison globale (AUC, calibration, Brier)

Lecture et choix "ranking vs décision".

- **Ranking (priorité fraude rare)** : `INTER_unw` est meilleur en **PR AUC** (0.8243), donc il sépare le mieux les fraudes sur l'ensemble des seuils.
- **ROC AUC très élevé** : `MAIN_unw` atteint 0.9947, mais ROC peut être moins discriminante en contexte très déséquilibré ; la PR AUC est plus directe pour la classe `Fraud`.

Table 4.3 – Comparatif des 6 modèles (tri implicite sur PR AUC dans l'analyse).

Modèle	ROC AUC	PR AUC	Brier	Cal. int.	Cal. slope	ECE	Seuil*
INTER_unw	0.9637	**0.8243**	**0.0052**	-0.657	0.437	**0.004**	0.45
INTER_w	0.9612	0.8102	0.0132	-2.018	0.273	0.015	0.99
MAIN_unw	**0.9947**	0.8038	0.0063	-0.313	**0.761**	**0.004**	0.45
STEP_unw	0.9339	0.8007	0.0067	-1.497	0.127	0.006	0.93
STEP_w	0.9330	0.7679	0.0080	-1.819	0.117	0.008	0.99
MAIN_w	0.9885	0.7320	0.0289	-3.142	0.549	0.038	0.98

*Seuil** = seuil maximisant le F1 sur le test (sélection par grille).

— **Calibration** : MAIN_unw a la pente la plus proche de 1 (0.761) ; les modèles pondérés ont des intercepts très négatifs et un ECE plus élevé ⇒ probabilités moins "calibrées" (normal : pondération modifie la cible implicite).

4.5.2 Performance au meilleur seuil (max F1)

Table 4.4 – Matrice de confusion et métriques au seuil optimisant F1 (test).

Modèle	TP	FP	FN	Precision	Recall	F1
MAIN_unw	23	6	8	0.7931	0.7419	0.7667
MAIN_w	22	13	9	0.6286	0.7097	0.6667
INTER_unw	23	5	8	**0.8214**	0.7419	0.7797
INTER_w	23	7	8	0.7667	0.7419	0.7541
STEP_unw	**24**	6	**7**	0.8000	**0.7742**	**0.7869**
STEP_w	**24**	8	**7**	0.7500	**0.7742**	0.7619

Conclusion opérationnelle (seuil fixe). Si l'objectif est un **point de décision** (alertes) optimisé F1 sur ce test, STEP_unw est légèrement devant (F1=0.7869). Si l'objectif est de **bien classer** (tri/priorisation des alertes) et de garder des probabilités propres, INTER_unw est le meilleur compromis (**PR AUC max** + **Brier min** + **ECE faible**).

4.6 Graphiques : ROC/PR et calibration (best model)

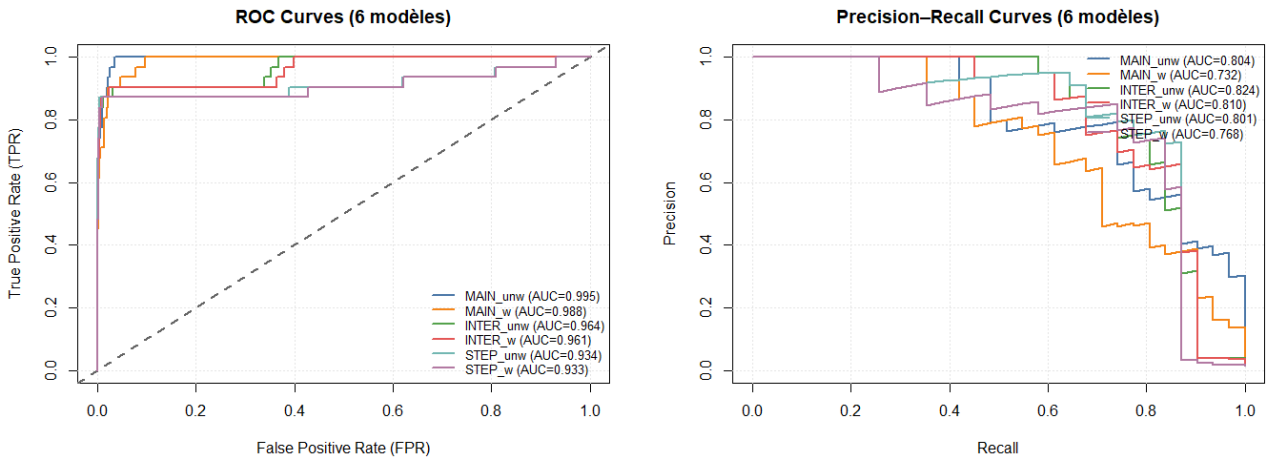

(a) ROC (6 modèles). (b) Precision–Recall (6 modèles).

Figure 4.1 – Comparaison globale : courbes ROC et PR (jeu de test).

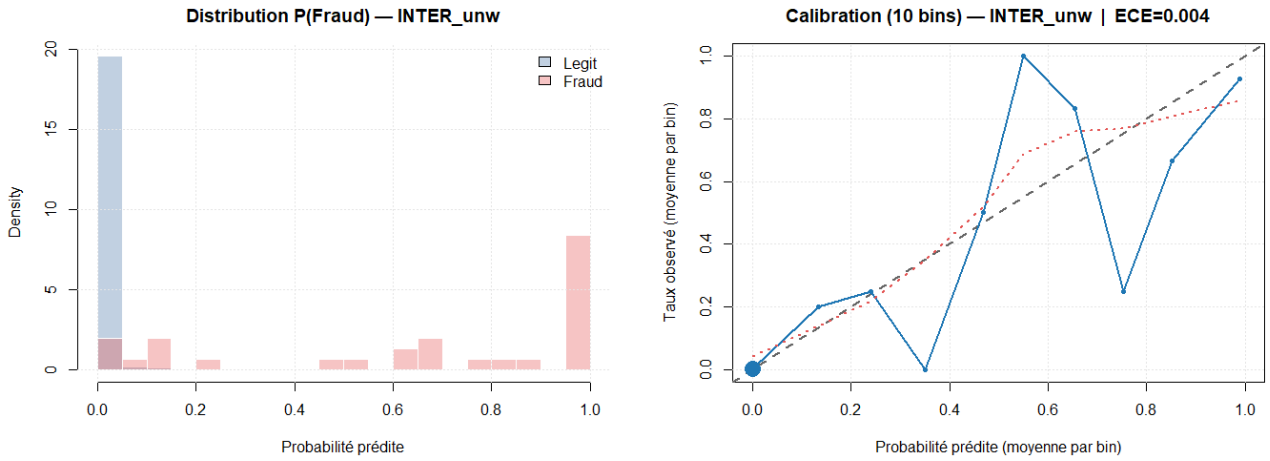

(a) Distribution de $P(\texttt{Fraud})$ pour `INTER_unw`.

(b) Calibration (10 bins) pour `INTER_unw` : ECE=0.004.

FIGURE 4.2 – Lecture probabiliste du meilleur modèle (`INTER_unw` selon PR AUC).

Lecture des graphes (points clés).

- **PR (Fig. 4.1)** : `INTER_unw` domine en aire sous courbe ⇒ meilleur compromis précision/rappel sur l'ensemble des seuils.
- **Histogramme (Fig. 4.2)** : les `Legit` sont massivement proches de 0, tandis que les `Fraud` sont davantage étalées vers 1 ⇒ bonne séparabilité.
- **Calibration (Fig. 4.2)** : ECE faible, mais la pente (0.437) suggère des probabilités parfois *trop extrêmes*. Avec fraude rare, l'ECE peut rester faible si la majorité des bins sont près de 0 : on privilégie une lecture conjointe ECE + slope.

4.7 Interprétation des coefficients : top variables du meilleur modèle

Le meilleur modèle selon PR AUC est `INTER_unw`. Les coefficients ci-dessous sont rapportés en **odds ratios** (OR) et IC 95%.

TABLE 4.5 – Top 15 termes (tri par p-value) — `INTER_unw`.

Terme	Coef	OR	IC 95% OR	p-value
`foreign_transactionYes`	8.3008	4027.262	[317.542 ; 51076.235]	1.51×10^{-10}
`location_mismatchYes`	8.1432	3439.980	[541.426 ; 21856.090]	6.03×10^{-18}
`log_amount`	-3.0653	0.047	[0.012 ; 0.182]	9.86×10^{-6}
`I(log_amount^2)`	0.4027	1.496	[1.267 ; 1.766]	2.03×10^{-6}
`I(velocity_last_24h^2)`	0.2008	1.222	[1.102 ; 1.356]	1.55×10^{-4}
`merchant_categoryFood`	-1.2261	0.293	[0.155 ; 0.552]	2.3×10^{-4}
`merchant_categoryTravel`	1.0112	2.749	[0.449 ; 16.839]	2.74×10^{-1}
`hour_group04-07`	-10.6516	0.000	[0.000 ; 0.979]	4.95×10^{-2}
`device_trust_score`	-0.2512	0.778	[0.723 ; 0.837]	2.46×10^{-11}
`cardholder_age`	0.0136	1.014	[1.004 ; 1.023]	5.0×10^{-3}
`foreign_trans:hour_group20-23`	1.8356	6.273	[1.925 ; 20.445]	3.0×10^{-3}
`merchant_cat:foreign_trans`	-1.0762	0.341	[0.150 ; 0.776]	1.0×10^{-2}
`hour_group12-15`	-0.8288	0.436	[0.229 ; 0.831]	1.2×10^{-2}
`hour_group16-19`	-8.7813	0.000	[0.000 ; 0.002]	6.36×10^{-10}

Interprétations "métier".

- `foreign_transactionYes` **et** `location_mismatchYes` : effets extrêmement forts (OR ≈ 4027 et ≈ 3440), cohérents avec l'analyse bivariée : transactions étrangères et incohérences géographiques sont des marqueurs de risque majeurs (attention : OR très grands, possiblement liés à une quasi-séparation sur certaines combinaisons).
- `device_trust_score` : effet protecteur marqué (OR ≈ 0.778 par point ; IC 95% [0.723; 0.837]) $\Rightarrow$ plus le score est élevé, plus le risque diminue.
- `velocity_last_24h` : l'effet est capté de façon **non linéaire** via `I(velocity_last_24h^2)` (OR ≈ 1.222 pour $+1$ sur $velocity^2$; IC 95% [1.102; 1.356]) : le risque augmente plus rapidement lorsque l'activité récente devient élevée (effet "accélérant").
- `hour_group` : plusieurs tranches ont des coefficients fortement négatifs (ex. `04-07`, `12-15`, `16-19`) $\Rightarrow$ elles sont beaucoup moins risquées que la tranche de référence (`00-03`), ce qui confirme le sur-risque nocturne.
- `log_amount` : présence d'un terme linéaire et quadratique (`log_amount` et `I(log_amount^2)`) $\Rightarrow$ relation non strictement linéaire entre montant et risque (cohérent avec un signal porté par la queue et motivant l'usage de la transformation log).

4.8 Conclusion

Les résultats confirment que la fraude est principalement portée par des **signaux contextuels et comportementaux**. Deux variables dominent nettement l'explication du risque : `foreign_transaction` et `location_mismatch` (OR $\gg 1$), ce qui est cohérent avec l'analyse bivariée. Elles sont complétées par des facteurs très discriminants : `device_trust_score` (risque **décroissant** lorsque le score augmente) et `velocity_last_24h` (risque **croissant** lorsque l'activité récente augmente, avec un effet **non linéaire** via `I(velocity_last_24h^2)`). Enfin, l'effet temporel est **fort** : plusieurs tranches horaires sont nettement moins risquées que la référence `00-03`, confirmant un sur-risque concentré la nuit.

Choix du modèle selon l'usage :

- **Priorisation des alertes (ranking)** : `INTER_unw` est le meilleur compromis sur le test (**PR AUC = 0.8243**, Brier = 0.0052, ECE = 0.004), ce qui en fait un candidat pertinent pour **classer** les transactions à investiguer.
- **Décision binaire (seuil optimisant F1)** : `STEP_unw` est légèrement supérieur (F1 = 0.7869), au prix d'une discrimination globale plus faible (ROC AUC ≈ 0.934).

Point d'attention : les versions pondérées peuvent améliorer ponctuellement la sensibilité, mais **dégradent la calibration** (et conduisent à des seuils très élevés). En pratique, il est préférable de retenir un modèle **non pondéré** bien évalué, et d'envisager une **recalibration** si l'on souhaite des probabilités directement exploitables.